

您的稿件编号: 2025040501

本稿件需要修改时请联系:

作者: 宋晨炜

手机号: 15067734428

邮箱: 2023210566@buct.edu.cn

http://www.joca.cn

doi:10.11772/j.issn.1001-9081.yyyymmnnnn

请务必确认好作者、单位、基金等相关信息, 投稿成功后不得随意修改

面向事件抽取的多阶段数据增强框架研究

宋晨炜¹, 江志英^{1*}, 韩众和^{2,3,4}, 王嘉薪¹

(1. 北京化工大学 信息科学与技术学院, 北京 100029;

2. 中国科学院 空天信息创新研究院, 北京 100190;

3. 中国科学院 网络信息技术重点实验室, 北京 100190;

4. 中国科学院 目标认知与应用技术重点实验室, 北京 100190)

(*通信作者电子邮箱 jiangzy@buct.edu.cn)

摘要: 事件抽取是自然语言处理领域的一项核心任务, 旨在从非结构化文本中精准识别事件触发词及关联论元。然而,

传统文本语料中面向事件抽取任务的高质量标注数据集极度稀缺, 严重制约了模型的泛化能力。现有数据增强方法(如同义词替换、回译等)虽能部分缓解数据稀疏问题, 但普遍存在语义结构破坏、多样性不足及噪声引入等缺陷。为此, 提出一种基于大语言模型(LLM)的多阶段协同增强框架, 通过数据生成-标注-判别校验-评分四阶段闭环机制, 在保持语义一致性的同时实现高质量多样化数据生成。具体而言: 生成模块融合多策略改写(如语义角色替换、事件结构重组)与约束性生成, 突破传统词级增强的局限性; 校验模块通过触发词-论元逻辑验证与事件模板匹配, 有效消除结构偏差; 评分模块基于信息完整性、语义一致性、事实合理性三维度筛选优质数据。在 ACE05-E+和 ERE-EN 数据集上的实验表明: 经所提框架增强后, Text2event 和 HDGSE 模型的触发词分类(Trig-C)和论元分类(Arg-C) F1 值较原始数据分别提升了 4.3、4.2 个百分点和 2.4、2.9 个百分点, 在论元分类(Arg-C) F1 值较原始数据分别提升了 3.6、5.2 个百分点和 2.8、3.5 个百分点; 相较于同义词替换、回译及 AugGPT 基线方法, 所提框架在两项任务上均达到最优性能(Trig-C/Arg-C F1 值领先幅度达 1.3~3.4 个百分点), 且消融实验证实各模块对性能提升贡献显著(如移除判别校验模块导致 F1 值下降 0.8~2.3 个百分点)。本研究为复杂结构化数据的增强提供了可扩展的解决方案, 显著提升了事件抽取模型在低资源场景下的鲁棒性。

关键词: 大语言模型; 数据增强; 事件抽取; 数据稀缺

中图分类号: TP391

文献标志码: A

Research on a Multi-Stage Data Augmentation Framework for Event Extraction

SONG Chenwei¹, JIANG Zhiying^{1*}, HAN Zhonghe^{2,3,4}, WANG Jiaxin¹

(1. College of Information Science and Technology, Beijing University of Chemical Technology, Beijing 100029;

2. The Aerospace Information Research Institute, Chinese Academic of Sciences, Beijing 100190;

3. Key Laboratory of Network Information System Technology, Institute of Electronic, Chinese Academy of Sciences, Beijing 100190;

4. Key Laboratory of Target Cognition and Application Technology, Chinese Academy of Sciences, Beijing 100190)

Abstract: Event extraction, a core task in natural language processing, aims to precisely identify event triggers and associated arguments from unstructured text. However, the scarcity of high-quality annotated datasets tailored for event extraction severely constrains model generalization. While existing data augmentation methods (e.g., synonym substitution, back-translation) partially alleviate data sparsity, they suffer from semantic structure distortion, limited diversity, and noise introduction. To address this, we propose a multi-stage LLM-based synergistic enhancement framework featuring a closed-loop mechanism of Generation-Annotation-Validation-Scoring, enabling high-quality diverse data generation while preserving semantic consistency. The generation module integrates multi-strategy rewriting (e.g., semantic role substitution, event structure restructuring) and constrained generation to transcend word-level augmentation limitations; the validation module eliminates structural bias through trigger-argument logical verification and event template matching; the scoring module filters data based on information integrity, semantic consistency,

收稿日期: 2025-05-07; 修回日期: 20yy-mm-dd; 录用日期: yyyy-mm-dd

基金项目: 目标认知与应用技术重点实验室资助(2023-CXPT-LC-005)

作者简介: 宋晨炜(1999—), 男, 浙江温州人, 硕士研究生, 主要研究方向: 自然语言处理、数据增强; 江志英(1987—), 江西景德镇人, 高级工程师, 博士, 主要研究方向: 大语言模型及自然语言处理、大数据实时分析; 韩众和(1993—), 河南郑州人, 副研究员, 硕士研究生, 主要研究方向: 深度学习、自然语言处理、大语言模型; 王嘉薪(2000—), 男, 吉林长春人, 硕士研究生, 主要研究方向: 自然语言处理、数据增强。

批注 [晨宋1]: 新意见 2: 同时论文实验部分应该加入如果用不同的事件抽取模型的性能对比
回复: 补充对数据增强框架对 HDGSE 模型性能的影响

3.3 实验设置¹

本文将 GPT-3.5-Turbo 作为实验选择的大语言模型，数据生成中将 temperature 设置为 0.8，来保证生成数据的多样性。本文所有实验均在一台 Nvidia RTX4090 GPU 上进行，本文通过数据增强框架的评分模块筛选出与原始数据一样规模大小的数据对真实训练集进行扩充，并对 Text2Event 和 HDGSE 模型进行微调。

4 实验与结果分析³

4.1 实验结果⁴

表 2 为本文的主要实验结果，其中 Trig-C 表示触发器词的识别和分类，Arg-C 表示论元的识别和分类。通过 Text2Event 和 HDGSE 事件抽取模型在 ACE05-E+ 和 ERE-EN 数据集上测试不同数据增强方法的效果。可以看出本文提出的数据增强方法在两个数据集上均达到了最优的性能。首先对于 Text2Event 事件抽取模型，在 ACE05-E+ 数据集上本文的方法在 Trig-C 上的 F1 达到了 76.1%，相较于基线模型 Text2Event 提升了 4.3 个百分点，在 Arg-C 上的 F1 达到了 58.0%，相较于 Text2Event 提升了 3.6 个百分点。对于 ENE-EN 数据集，它相较于 ACE05-E+ 拥有更多的事件和角色，事件结构更为丰富，本文的方法同样在 Trig-C 和 Arg-C 上的 F1 达到最高值，对比基线模型 Text2Event 分别提升了 4.2 个百分点和 5.2 个百分点。在 HDGSE 事件抽取模型上，本文的数据增强方法在两个数据集上同样展现出显著优势。在 ACE05-E+ 数据集的 Trig-C 上的 F1 达到 79.6%，较基线模型

HDGSE 提升 2.4 个百分点，在 Arg-C 上的 F1 达到 60.5%，较基线模型 HDGSE 提升 2.8 个百分点。对事件角色更为丰富的 ERE-EN 数据集，本文的方法同样在 Trig-C 和 Arg-C 上展现出优势，对比基线模型 HDGSE 分别提升了 2.9 个百分点和 3.5 个百分点。因此表 2 的实验结果表明本文提出的基于大语言模型的多阶段数据增强框架在事件抽取任务上的有效性。

对于同义词替换和回译两种基线方法，后者本是句子级增强，但为了尽量不破坏原有的事件结构，本文将句子回译替换为单词回译。由表 2 可以看出两种方法相较基线模型有一定的提升，但只是单词级别的修改，并没有对文本带来很大的变化，对模型性能的提升并没有这么明显。而对于 AugGPT 生成式方法，总体上是优于同义词替换和回译两种方法，但低于本文的数据增强方法，虽然 AugGPT 生成的数据弥补了多样性的不足，但因事件结构的偏差可能导致性能受限。不同于改写方法，对于直接利用大模型生成的方法其 F1 值均低于基线模型。在没有追加任何策略（如事件论元角色描述，小样本学习等）的情况下，LLMDirectGen 方法生成的数据严重偏离真实事件分布。造成的可能原因是在特定的专业领域下，大语言模型不能充分理解事件类型与论元角色所表达的意思，所以导致事件结构标注错误，甚至是随意标注且不在生成的句子中。更值得一提的，这样的方法生成的句子结构，语法单一，不利于数据多样性的引入。由此可以看出本文提出的基于大语言模型的多阶段数据增强框架可以有效的提升数据集的质量，在多样化事件要素构造上更有优势。

批注 [晨宋8]: 新意见 1: 主要表现在对比实验应加上大模型直接生成事件数据的结果
回复: 补充对大语言模型直接生成事件数据的结果分析

表2 不同数据增强方法的对比结果⁸

Tab. 2 Comparison Results of Different Data Augmentation Methods⁹

模型	增强方法	ACE05-E+						ERE-EN					
		Trig-C			Arg-C			Trig-C			Arg-C		
		P	R	F1	P	R	F1	P	R	F1	P	R	F1
TEXT2EVENT	None	71.2	72.5	71.8	54.0	54.8	54.4	59.2	59.6	59.4	49.4	47.2	48.3
	LLMDirectGen	64.8	67.9	66.3	48.4	50.4	49.4	53.5	54.6	54.0	42.0	45.2	43.5
	同义词替换 SR	71.9	74.2	73.0	54.5	55.7	55.1	60.4	61.3	60.8	50.8	50.5	50.6
	回译 BT	71.6	73.9	72.7	54.3	55.1	54.7	60.9	61.7	61.3	51.0	49.6	50.3
	AugGPT	72.1	73.6	72.8	54.8	56.4	55.6	60.5	62.1	61.3	51.2	51.0	51.1
	本文方法	74.3	77.9	76.1	57.7	58.4	58.0	64.5	62.8	63.6	52.9	54.1	53.5
HDGSE	None	75.5	79.0	77.2	57.6	57.8	57.7	64.5	67.9	66.1	54.5	52.6	53.5
	LLMDirectGen	69.3	73.6	71.4	51.8	54.3	53.0	59.7	62.4	61.0	50.1	48.4	49.2
	同义词替换	75.9	80.1	77.9	58.4	59.3	58.8	64.7	68.3	66.5	54.8	53.1	53.9
	回译	75.7	79.5	77.6	57.8	58.2	58.0	64.9	68.2	66.5	55.0	53.4	54.2
	AugGPT	76.3	80.4	78.3	58.2	59.6	58.9	64.7	68.6	66.6	54.7	53.6	54.1
	本文方法	77.9	81.3	79.6	60.1	60.9	60.5	67.9	70.1	69.0	56.3	57.8	57.0

4.2 数据分析¹¹

表 3 展示了通过本文数据增强方法处理后的数据规模统计结果。在 ACE05-EN+ 数据集中，事件数量经增强扩展至 9931 个，对应论元角色数量达 13425 个；而 ERE-EN 数据集

批注 [晨宋9]: 新意见 1: 主要表现在对比实验应加上大模型直接生成事件数据的结果
回复: 补充使用大模型直接生成带有事件结构的句子。

批注 [晨宋9]: 新意见 1: 主要表现在对比实验应加上大模型直接生成事件数据的结果
回复: 补充使用大模型直接生成带有事件结构的句子。

批注 [晨宋10]: 意见: 实验对比中，baseline 方法 SR 和 BT 是什么？作者需要用已发表的科研方法作为 baseline。
回复: SR 和 BT 为 3.2.1 所提到同义词替换和回译两种数据增强方法，在 3.2.1 进行了文献引用。

批注 [晨宋11]: 新意见 2: 同时论文实验部分应该加入如果用不同的事件抽取模型的性能对比
回复: 补充 HDGSE 事件抽取模型的性能对比

conference of the North American chapter of the association for computational linguistics: human language technologies, F, 2016 [C].

[20] PAOLINI G, ATHIWARATKUN B, KRONE J, et al. Structured prediction as translation between augmented natural languages [J]. arXiv preprint arXiv:210105779, 2021.

[21] HUANG H, LIU X, SHI G, et al. Event extraction with dynamic prefix tuning and relevance retrieval [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(10): 9946-58.

[22] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback [J]. Advances in neural information processing systems, 2022, 35: 27730-44.

[23] WEI X, CUI X, CHENG N, et al. Zero-shot information extraction via chatting with chatgpt [J]. arXiv e-prints, 2023: arXiv: 2302.10205.

[24] DEVLIN J, CHANG M-W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding: proceedings of the Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers), E, 2019 [C].

[25] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models [J]. Advances in neural information processing systems, 2022, 35: 24824-37.

[26] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models [J]. arXiv preprint arXiv:220311171, 2022.

[27] MILLER G A. WordNet: a lexical database for English [J]. Communications of the ACM, 1995, 38(11): 39-41.

[28] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer [J]. Journal of machine learning research, 2020, 21(140): 1-67.

This work is partially supported by Key Laboratory of Target Cognition and Application Technology(2023-CXPT-LC-005)

JIANG Zhiying, born in 1987, Ph. D., associate professor. His research interests include large language model, natural language processing, real-time big data analytics.

SONG Chenwei, born in 1999, M. S. candidate. His research interests include natural language processing, data augmentation

HAN Zhonghe, born in 1993, M. S, associate researcher. His research interests include deep learning, natural language processing, large language model.

WANG Jiaxin, born in 2000, M. S. candidate. His research interests include natural language processing, data augmentation.

★本文矩阵、矢量/向量等变量符号说明（投稿时须附上相应内容）：

矩阵、矢量也是变量，正文用 **Times New Rome** 字体斜体加粗表示，其他变量用常规斜体即可，公式编辑器设置见图中示例；没有矩阵、矢量变量的填写“无”。需要注意：尽量不要使用同一字母的普通斜体及加粗斜体来表示不同变量，非常容易混淆；更不能错误地使用同一变量字母来表示不同含义的变量。

变量符号	含义	备注
无	说明其在本文中表的含义	矩阵
无	说明其在本文中表的含义	矢量



★研究背景、基金项目介绍（投稿时须附上相应内容）：

【请提供与本文内容直接相关的工作背景、本文基金项目等的简要说明与介绍，不是指整个行业的研究背景，而是介绍作者写作本文内容涉及的具体应用技术背景等，所有基金依次填写以下表格内容】